



UNIVERSIDADE
FEDERAL DO CEARÁ



Aprendizagem de Máquina Probabilística

César Lincoln Cavalcante Mattos

2024

Agenda

- ① Classificação binária
- ② Regressão logística binária
- ③ Classificação logística multiclasse
- ④ Regressão logística via algoritmo IRLS
- ⑤ Regressão logística Bayesiana - Aproximação de Laplace
- ⑥ Tópicos adicionais
- ⑦ Referências


Classificação

Tarefa de classificação

Relaciona vetores de entrada a um número finito de rótulos/categorias/classes de saída.

- **Classificação binária:** Somente duas classes (sim/não, positivo/negativo, gato/cachorro, etc.)
- **Classificação multiclasse:** Mais de duas classes (dígitos, letras, raças de cachorro, marcas de carro, etc.)

Classificação binária




Iris Versicolor



Iris Setosa

- **Problema:** Como classificar automaticamente flores da espécie íris entre Setosa e Versicolor a partir de medidas de suas sépalas?

Classificação binária



- **Ideia:** Podemos utilizar um modelo de regressão linear nessa tarefa de classificação?

Classificação binária

- Convertemos as saídas categóricas (“setosa” ou “versicolor”) em números: -1 ou 1 .

Classificação binária

- Convertemos as saídas categóricas (“setosa” ou “versicolor”) em números: -1 ou 1 .
- **Problema:** O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.

Classificação binária

- Convertemos as saídas categóricas (“setosa” ou “versicolor”) em números: -1 ou 1 .
- **Problema:** O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.
- **Ideia:** Modificar a saída para $\hat{y}_i = \text{sign}(\mathbf{w}^\top \mathbf{x}_i)$, em que:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = \begin{cases} -1 & , \text{ se } \mathbf{w}^\top \mathbf{x}_i < 0 \\ 1 & , \text{ se } \mathbf{w}^\top \mathbf{x}_i \geq 0 \end{cases} .$$

Classificação binária

- Convertemos as saídas categóricas (“setosa” ou “versicolor”) em números: -1 ou 1 .
- **Problema:** O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.
- **Ideia:** Modificar a saída para $\hat{y}_i = \text{sign}(\mathbf{w}^\top \mathbf{x}_i)$, em que:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = \begin{cases} -1 & , \text{ se } \mathbf{w}^\top \mathbf{x}_i < 0 \\ 1 & , \text{ se } \mathbf{w}^\top \mathbf{x}_i \geq 0 \end{cases} .$$

- **Problema:** Como modificar a regra de atualização dos parâmetros, dado que a função $\text{sign}(\cdot)$ não é diferenciável?

Classificação binária


- Convertemos as saídas categóricas (“setosa” ou “versicolor”) em números: -1 ou 1 .
- **Problema:** O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.
- **Ideia:** Modificar a saída para $\hat{y}_i = \text{sign}(\mathbf{w}^\top \mathbf{x}_i)$, em que:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = \begin{cases} -1 & , \text{ se } \mathbf{w}^\top \mathbf{x}_i < 0 \\ 1 & , \text{ se } \mathbf{w}^\top \mathbf{x}_i \geq 0 \end{cases} .$$

- **Problema:** Como modificar a regra de atualização dos parâmetros, dado que a função $\text{sign}(\cdot)$ não é diferenciável?
- **Ideia:** Vamos usar a função $\text{sign}(\cdot)$ somente na predição do modelo.

Classificação binária

- Solução via OLS: $\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$
- Classificação binária (70% para treinamento e 30% para teste):



Agenda

- 1 Classificação binária
- 2 Regressão logística binária
- 3 Classificação logística multiclasse
- 4 Regressão logística via algoritmo IRLS
- 5 Regressão logística Bayesiana - Aproximação de Laplace
- 6 Tópicos adicionais
- 7 Referências


Classificação binária

- **Ideia:** Trocar a função $\text{sign}(\cdot)$ por uma função diferenciável entre 0 e 1.

Classificação binária

- **Ideia:** Trocar a função $\text{sign}(\cdot)$ por uma função diferenciável entre 0 e 1.
- **Função logística (sigmóide):**

$$\sigma(z) = \frac{1}{1 + \exp(-z)}.$$



Classificação binária

Regressão logística

- Apesar do nome, é um método de **classificação**.
- Usa uma **função logística** na saída do modelo linear:

$$\hat{y}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i), \quad \sigma(z) = \frac{1}{1 + \exp(-z)}.$$

- A função logística é definida no intervalo $[0, 1]$, possuindo interpretação probabilística.
- $\sigma(z)$ é facilmente **diferenciável**:

$$\frac{d\sigma(z)}{dz} = \sigma(z)(1 - \sigma(z)).$$

Regressão logística binária

- **Problema:** Como modelar probabilisticamente os dados a partir da função logística?

Regressão logística binária

- **Problema:** Como modelar probabilisticamente os dados a partir da função logística?

Distribuição de Bernoulli

- Seja uma moeda potencialmente injusta (cara (1) e coroa (0)):

$$P(y = 1|q) = q,$$

$$P(y = 0|q) = 1 - q.$$

- A Distribuição de Bernoulli é então definida por:

$$p(y|q) = q^y(1 - q)^{1-y}.$$

Regressão logística binária

- **Problema:** Como modelar probabilisticamente os dados a partir da função logística?

Distribuição de Bernoulli

- Considerando duas classes, 0 e 1, temos:

$$P(y = 1|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x}),$$

$$P(y = 0|\mathbf{x}, \mathbf{w}) = 1 - \sigma(\mathbf{w}^\top \mathbf{x}).$$

- A Distribuição de Bernoulli é então definida por:

$$p(y|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x})^y (1 - \sigma(\mathbf{w}^\top \mathbf{x}))^{1-y}.$$

Regressão logística binária

- **Problema:** Qual será a nova função custo?

Regressão logística binária

- **Problema:** Qual será a nova função custo?
- **Ideia:** Escolher o negativo da **log-verossimilhança**:

$$\mathcal{J}(\mathbf{w}) = -\log p(\mathbf{y}|\mathbf{X}, \mathbf{w})$$

$$\mathcal{J}(\mathbf{w}) = -\log \prod_{i=1}^N p(y_i|\mathbf{x}_i, \mathbf{w})$$

$$\mathcal{J}(\mathbf{w}) = -\log \prod_{i=1}^N \sigma(\mathbf{w}^\top \mathbf{x}_i)^{y_i} (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))^{1-y_i}$$

$$\mathcal{J}(\mathbf{w}) = -\sum_{i=1}^N [y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))] .$$

Regressão logística binária

Cross entropy loss

- Definida por:

$$\mathcal{J}(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))] .$$

- Precisamos calcular o gradiente da função custo para atualizar os parâmetros do modelo:

$$\mathbf{w} \leftarrow \mathbf{w} - \alpha \frac{\partial \mathcal{J}(\mathbf{w})}{\partial \mathbf{w}} .$$

Regressão logística binária

- Derivando em relação a \mathbf{w} , temos:

$$\begin{aligned}\mathcal{J}(\mathbf{w}) &= -\frac{1}{N} \sum_{i=1}^N \left[y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \right], \\ \frac{\partial \mathcal{J}(\mathbf{w})}{\partial \mathbf{w}} &= -\frac{1}{N} \sum_{i=1}^N \left[y_i \frac{1}{\sigma(\mathbf{w}^\top \mathbf{x}_i)} \frac{\partial \sigma(\mathbf{w}^\top \mathbf{x}_i)}{\partial \mathbf{w}} - (1 - y_i) \frac{1}{1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)} \frac{\partial \sigma(\mathbf{w}^\top \mathbf{x}_i)}{\partial \mathbf{w}} \right] \\ &= -\frac{1}{N} \sum_{i=1}^N \left[y_i \frac{\sigma(\mathbf{w}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))}{\sigma(\mathbf{w}^\top \mathbf{x}_i)} \mathbf{x}_i - (1 - y_i) \frac{\sigma(\mathbf{w}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))}{1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)} \mathbf{x}_i \right] \\ &= -\frac{1}{N} \sum_{i=1}^N \left[y_i(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \mathbf{x}_i - (1 - y_i) \sigma(\mathbf{w}^\top \mathbf{x}_i) \mathbf{x}_i \right] \\ &= -\frac{1}{N} \sum_{i=1}^N \left[y_i \mathbf{x}_i - y_i \sigma(\mathbf{w}^\top \mathbf{x}_i) \mathbf{x}_i - \sigma(\mathbf{w}^\top \mathbf{x}_i) \mathbf{x}_i + y_i \sigma(\mathbf{w}^\top \mathbf{x}_i) \mathbf{x}_i \right] \\ &= -\frac{1}{N} \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \mathbf{x}_i \\ &= -\frac{1}{N} \sum_{i=1}^N e_i \mathbf{x}_i.\end{aligned}$$

Regressão logística binária

- Com o gradiente $\frac{\partial \mathcal{J}(\mathbf{w})}{\partial \mathbf{w}}$, atualizamos o modelo via GD ou SGD.

Gradiente Descendente (GD)

- Regra de atualização:

$$\mathbf{w}(t) = \mathbf{w}(t-1) + \alpha \frac{1}{N} \sum_{i=1}^N e_i(t-1) \mathbf{x}_i$$

Gradiente Descendente Estocástico (SGD)


- Regra de atualização:

$$\mathbf{w}(t) = \mathbf{w}(t-1) + \alpha e_i(t-1) \mathbf{x}_i$$


- Lembrando que na regressão logística temos:

$$e_i(t) = y_i - \sigma(\mathbf{w}(t)^\top \mathbf{x}_i)$$

Exemplo de classificação (dados separáveis linearmente)




Regressão logística via GD



Regressão logística via SGD

Exemplo de classificação (dados não separáveis linearmente)



Regressão logística binária

Extensões da regressão logística


- Novos **atributos não-lineares** (x_i^2, x_i^3, \dots) podem ser incluídos para obter um **classificador não-linear**.

Regressão logística binária

Extensões da regressão logística

- Novos **atributos não-lineares** (x_i^2, x_i^3, \dots) podem ser incluídos para obter um **classificador não-linear**.
- Modelos de regressão logística também podem ser **regularizados**.
 - Inclui na função custo o termo: $+\lambda\|\mathbf{w}\|^2$.
 - Inclui na regra de atualização o termo: $-\lambda\mathbf{w}(t-1)$.


Exemplo de classificação com atributos polinomiais



Agenda

- 1 Classificação binária
- 2 Regressão logística binária
- 3 Classificação logística multiclasse**
- 4 Regressão logística via algoritmo IRLS
- 5 Regressão logística Bayesiana - Aproximação de Laplace
- 6 Tópicos adicionais
- 7 Referências

Classificação multiclasse



Iris Versicolor




Iris Setosa



Iris Virginica

- **Problema:** Como classificar automaticamente flores da espécie íris entre Setosa, Versicolor e Virgínica a partir de medidas de suas pétalas?


Classificação multiclasse



- **Problema:** Como representamos as classes na saída do modelo?


Classificação multiclasse

- **Ideia:** $K - 1$ classificações binárias **one vs all**:



Classificação multiclasse


- **Ideia:** $K - 1$ classificações binárias **one vs all**:



- **Problema:** Regiões não associadas a uma única classe.


Classificação multiclasse

- **Ideia:** $K(K - 1)/2$ classificações binárias **one vs one**:



Classificação multiclasse

- **Ideia:** $K(K - 1)/2$ classificações binárias **one vs one**:



- **Problema:** Regiões não associadas a uma única classe.

Classificação multiclasse

One hot encoding (1-of- K encoding)

- A saída do modelo é um vetor de K elementos (K = número de classes).
- O vetor de saída desejado \mathbf{y}_i consiste em um vetor de $K - 1$ zeros e um valor 1 na k -ésima posição associada à k -ésima classe.
- **Exemplo:** $\mathbf{y}_i = [1\ 0\ 0]^\top$, ou $\mathbf{y}_i = [0\ 1\ 0]^\top$, ou $\mathbf{y}_i = [0\ 0\ 1]^\top$.

Classificação multiclasse

One hot encoding (1-of- K encoding)

- A saída do modelo é um vetor de K elementos (K = número de classes).
- O vetor de saída desejado \mathbf{y}_i consiste em um vetor de $K - 1$ zeros e um valor 1 na k -ésima posição associada à k -ésima classe.
- **Exemplo:** $\mathbf{y}_i = [1 \ 0 \ 0]^\top$, ou $\mathbf{y}_i = [0 \ 1 \ 0]^\top$, ou $\mathbf{y}_i = [0 \ 0 \ 1]^\top$.


Discriminante linear

- Dado um total de K classes, a classe k_* predita para o padrão \mathbf{x}_* é dada por:

$$k_* = \arg \max_{1 \leq k \leq K} \hat{y}_k.$$


Classificação multiclasse

- As regiões definidas por um discriminante linear são **convexas**:



Classificação multiclasse

- As regiões definidas por um discriminante linear são **convexas**:



- Problema:** Notação do modelo com múltiplas saídas?

Regressão multivariada

- Nova notação matricial:

$$\hat{\mathbf{y}}_i = \mathbf{W}^\top \mathbf{x}_i,$$

$$\hat{\mathbf{Y}} = \mathbf{X}\mathbf{W},$$

- $\mathbf{W} \in \mathbb{R}^{D \times K}$ é a matriz de parâmetros do modelo.
- $\mathbf{X} \in \mathbb{R}^{N \times D}$ é a coleção de entradas do modelo.
- $\hat{\mathbf{Y}} \in \mathbb{R}^{N \times K}$ é a coleção de saídas do modelo.

Regressão multivariada

OLS para regressão multivariada (múltiplas saídas)

- **Função custo:**

$$\mathcal{J}(\mathbf{W}) = \frac{1}{2} \|\mathbf{Y} - \hat{\mathbf{Y}}\|_F^2 = \frac{1}{2} \sum_{i=1}^N \|\mathbf{y}_i - \hat{\mathbf{y}}_i\|^2 = \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^K |y_{ik} - \hat{y}_{ik}|^2,$$

em que $\|\cdot\|_F$ é a **Norma de Frobenius**.

- **Solução analítica:**

$$\mathbf{W} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Regressão multivariada

Gradiente Descendente para múltiplas saídas

- Regra de atualização:

$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha \frac{1}{N} \sum_{i=1}^N e_{ik}(t-1) \mathbf{x}_i$$

Gradiente Descendente Estocástico para múltiplas saídas

- Regra de atualização:

$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha e_{ik}(t-1) \mathbf{x}_i$$

- Note que:

$$\rightarrow e_{ik} = y_{ik} - \hat{y}_{ik}$$

$$\rightarrow \mathbf{W} = [\mathbf{w}_1 \cdots \mathbf{w}_k \cdots \mathbf{w}_K], \mathbf{w}_k \in \mathbb{R}^D$$

Classificação multiclasse

Regressão logística multiclasse

- A coluna \mathbf{w}_k da matriz \mathbf{W} está associada à classe k .

Classificação multiclasse

Regressão logística multiclasse

- A coluna \mathbf{w}_k da matriz \mathbf{W} está associada à classe k .
- Para a saída do modelo, usamos a função **softmax**:

$$\hat{y}_{ik} = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K.$$

Classificação multiclasse

Regressão logística multiclasse

- A coluna \mathbf{w}_k da matriz \mathbf{W} está associada à classe k .
- Para a saída do modelo, usamos a função **softmax**:

$$\hat{y}_{ik} = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K.$$

- Interpretação probabilística: $\hat{y}_{ik} = p(y_{ik} | \mathbf{x}_i, \mathbf{W}) \in [0, 1]$.
- Também chamada de **regressão softmax** ou **regressão logística multinomial**.

Classificação multiclasse

Regressão logística multiclasse

- A coluna \mathbf{w}_k da matriz \mathbf{W} está associada à classe k .
- Para a saída do modelo, usamos a função **softmax**:

$$\hat{y}_{ik} = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K.$$

- Interpretação probabilística: $\hat{y}_{ik} = p(y_{ik} | \mathbf{x}_i, \mathbf{W}) \in [0, 1]$.
 - Também chamada de **regressão softmax** ou **regressão logística multinomial**.
-
- **Problema:** Qual será a nova função custo?

Regressão logística multiclasse

Multiclass cross-entropy

- Função custo para regressão logística multiclasse:

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \log p(\mathbf{Y}|\mathbf{X}, \mathbf{W})$$

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \log \prod_{i=1}^N \prod_{k=1}^K p(y_{ik}|\mathbf{x}_i, \mathbf{W})^{y_{ik}}$$

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log \hat{y}_{ik}.$$

- Precisamos calcular o gradiente da função custo para atualizar os parâmetros do modelo:

$$\mathbf{W} \leftarrow \mathbf{W} - \alpha \frac{\partial \mathcal{J}(\mathbf{W})}{\partial \mathbf{W}}, \text{ ou } \mathbf{w}_k \leftarrow \mathbf{w}_k - \alpha \frac{\partial \mathcal{J}(\mathbf{W})}{\partial \mathbf{w}_k}, \forall k.$$

Regressão logística multiclasse

- As derivadas em relação aos parâmetros são dadas por:

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K y_{ij} \log \hat{y}_{ij},$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K \frac{y_{ij}}{\hat{y}_{ij}} \frac{\partial \hat{y}_{ij}}{\partial \mathbf{w}_k},$$

em que

$$\frac{\partial \hat{y}_{ik}}{\partial \mathbf{w}_k} = (\hat{y}_{ik} - \hat{y}_{ik}^2) \mathbf{x}_i, \quad j = k,$$

$$\frac{\partial \hat{y}_{ij}}{\partial \mathbf{w}_k} = -\hat{y}_{ij} \hat{y}_{ik} \mathbf{x}_i, \quad j \neq k,$$

ou seja,

$$\frac{\partial \hat{y}_{ij}}{\partial \mathbf{w}_k} = [\delta(j, k) \hat{y}_{ik} - \hat{y}_{ij} \hat{y}_{ik}] \mathbf{x}_i, \quad \delta(j, k) = \begin{cases} 1, & j = k, \\ 0, & j \neq k \end{cases}.$$

Regressão logística multiclasse

- Substituindo na derivada original:

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K \frac{y_{ij}}{\hat{y}_{ij}} [\delta(j, k) \hat{y}_{ij} - \hat{y}_{ij} \hat{y}_{ik}] \mathbf{x}_i$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K y_{ij} [\delta(j, k) - \hat{y}_{ik}] \mathbf{x}_i$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N} \sum_{i=1}^N \left[\sum_{j=1}^K y_{ij} \delta(j, k) - \hat{y}_{ik} \sum_{j=1}^K y_{ij} \right] \mathbf{x}_i$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N} \sum_{i=1}^N [y_{ik} - \hat{y}_{ik}] \mathbf{x}_i = -\frac{1}{N} \sum_{i=1}^N e_{ik} \mathbf{x}_i.$$

- Note que usamos acima o fato da soma dos elementos do vetor \mathbf{y}_i ser igual a 1.

Regressão logística multiclasse

- Com os gradientes $\frac{\partial \mathcal{J}(\mathbf{W})}{\partial \mathbf{w}_k}$, atualizamos o modelo via GD/SGD.

Gradiente Descendente para múltiplas saídas

- Regra de atualização:

$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha \frac{1}{N} \sum_{i=1}^N e_{ik}(t-1) \mathbf{x}_i$$

Gradiente Descendente Estocástico para múltiplas saídas

- Regra de atualização:


$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha e_{ik}(t-1) \mathbf{x}_i$$

- Lembrando que na regressão logística multiclasse temos:

$$e_{ik} = y_{ik} - \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x}_i)}.$$


Classificação multiclasse

Regressão linear “ingênua” (OLS) - 72.73% de acurácia no teste




Classificação multiclasse

Regressão logística (GD) - 93.18% de acurácia no teste



Classificação multiclasse

Regressão logística (SGD) - 93.18% de acurácia no teste



Agenda

- 1 Classificação binária
- 2 Regressão logística binária
- 3 Classificação logística multiclasse
- 4 Regressão logística via algoritmo IRLS
- 5 Regressão logística Bayesiana - Aproximação de Laplace
- 6 Tópicos adicionais
- 7 Referências

Algoritmo IRLS

- Por causa da não-linearidade da função sigmoide, não há uma solução analítica para a regressão logística.

Algoritmo IRLS

- Por causa da não-linearidade da função sigmoide, não há uma solução analítica para a regressão logística.
- **IRLS (iterative reweighted least squares)**: Aplicação iterativa do algoritmo de Newton-Raphson:

$$\mathbf{w}_t = \mathbf{w}_{t-1} - (\nabla \nabla \mathcal{J}(\mathbf{w}_{t-1}))^{-1} \nabla \mathcal{J}(\mathbf{w}_{t-1}),$$

em que $\mathcal{J}(\mathbf{w})$ é a função custo, $\nabla \mathcal{J}(\mathbf{w})$ é o seu gradiente em relação aos parâmetros \mathbf{w} e $\nabla \nabla \mathcal{J}(\mathbf{w})$ é a sua Hessiana.

Algoritmo IRLS

- Computamos o gradiente e a Hessiana da função custo $\mathcal{J}(\mathbf{w})$:

$$\mathcal{J}(\mathbf{w}) = - \sum_{i=1}^N \left[y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \right],$$

$$\nabla \mathcal{J}(\mathbf{w}) = - \sum_{i=1}^N (y_i - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \mathbf{x}_i = -\mathbf{X}^\top (\mathbf{y} - \sigma(\mathbf{X}\mathbf{w})),$$

$$\nabla \nabla \mathcal{J}(\mathbf{w}) = \sum_{i=1}^N \sigma(\mathbf{w}^\top \mathbf{x}_i) (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \mathbf{x}_i \mathbf{x}_i^\top = \mathbf{X}^\top \mathbf{R} \mathbf{X},$$

$$\mathbf{R} = \text{diag}(R_{11}, \dots, R_{NN}),$$

$$R_{ii} = \sigma(\mathbf{w}^\top \mathbf{x}_i) (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)).$$

Algoritmo IRLS

- Os parâmetros \mathbf{w} são atualizados via IRLS da seguinte maneira:

$$\begin{aligned}\mathbf{w}_t &= \mathbf{w}_{t-1} - (\nabla \nabla \mathcal{J}(\mathbf{w}_{t-1}))^{-1} \nabla \mathcal{J}(\mathbf{w}_{t-1}) \\ &= \mathbf{w}_{t-1} + (\mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{y} - \sigma(\mathbf{X} \mathbf{w}_{t-1})) \\ &= (\mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X})^{-1} [\mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X} \mathbf{w}_{t-1} + \mathbf{X}^\top (\mathbf{y} - \sigma(\mathbf{X} \mathbf{w}_{t-1}))] \\ &= (\mathbf{X}^\top \mathbf{R} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{z}_{t-1},\end{aligned}$$

em que:

$$\begin{aligned}\mathbf{R}_{t-1} &= \text{diag}([R_{t-1}]_{11}, \dots, [R_{t-1}]_{NN}), \\ [R_{t-1}]_{ii} &= \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)), \\ \mathbf{z}_{t-1} &= \mathbf{X} \mathbf{w}_{t-1} + \mathbf{R}_{t-1}^{-1} (\mathbf{y} - \sigma(\mathbf{X} \mathbf{w}_{t-1})).\end{aligned}$$

- Pode ser extrapolado para o caso multiclasse (Murphy, pgs. 252-254).

Algoritmo IRLS - Solução MAP

- Considerando uma priori $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0)$, temos:

$$\mathcal{J}_{\text{MAP}}(\mathbf{w}) = \mathcal{J}(\mathbf{w}) - \log \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0).$$

- O gradiente e a Hessiana modificados serão dados por:

$$\nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}) = \nabla \mathcal{J}(\mathbf{w}) + \mathbf{S}_0^{-1}(\mathbf{w} - \mathbf{m}_0),$$

$$\nabla \nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}) = \nabla \nabla \mathcal{J}(\mathbf{w}) + \mathbf{S}_0^{-1}.$$

- A solução iterativa MAP do IRLS é computada por:

$$\begin{aligned}\mathbf{w}_t &= \mathbf{w}_{t-1} - (\nabla \nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}_{t-1}))^{-1} \nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}_{t-1}) \\ &= \mathbf{w}_{t-1} + \mathbf{A}^{-1} [\mathbf{X}^\top (\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1})) - \mathbf{S}_0^{-1}(\mathbf{w}_{t-1} - \mathbf{m}_0)],\end{aligned}$$

em que:

$$\mathbf{A} = \mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X} + \mathbf{S}_0^{-1},$$

$$\mathbf{R}_{t-1} = \text{diag}([R_{t-1}]_{11}, \dots, [R_{t-1}]_{NN}),$$

$$[R_{t-1}]_{ii} = \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)).$$

Algoritmo IRLS - Solução MAP

Resumo do algoritmo

- Passo de estimação

- 1 Defina a partir de conhecimentos/experimentos anteriores:

- os momentos da priori $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0)$;

- o valor inicial de $\mathbf{w}_0 \in \mathbb{R}^D$.

- 2 A partir dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, repita até convergir:

$$\mathbf{w}_t = \mathbf{w}_{t-1} + \mathbf{A}^{-1}[\mathbf{X}^\top (\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1})) - \mathbf{S}_0^{-1}(\mathbf{w}_{t-1} - \mathbf{m}_0)],$$

em que:

$$\mathbf{A} = \mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X} + \mathbf{S}_0^{-1},$$

$$\mathbf{R}_{t-1} = \text{diag}([R_{t-1}]_{11}, \dots, [R_{t-1}]_{NN}),$$

$$[R_{t-1}]_{ii} = \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)).$$

- 3 Retorne os parâmetros estimados $\hat{\mathbf{w}}$.

- Passo de predição

- 1 Dado um padrão \mathbf{x}_* , retorne a predição:

$$p(y_* = 1|\mathbf{x}_*) = \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_*).$$

Agenda

- 1 Classificação binária
- 2 Regressão logística binária
- 3 Classificação logística multiclasse
- 4 Regressão logística via algoritmo IRLS
- 5 Regressão logística Bayesiana - Aproximação de Laplace
- 6 Tópicos adicionais
- 7 Referências

Regressão logística Bayesiana

- Considere um modelo de regressão logística binária:

$$\begin{aligned} p(\mathbf{y}|\mathbf{X}, \mathbf{w}) &= \prod_{i=1}^N \sigma(\mathbf{w}^\top \mathbf{x}_i)^{y_i} (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))^{1-y_i}, \quad y_i \in \{0, 1\}, \\ &= \prod_{i=1}^N \sigma_i^{y_i} (1 - \sigma_i^{1-y_i}), \end{aligned}$$

$$\text{em que } \sigma_i = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x}_i)}.$$

- Considere uma priori Gaussiana para o vetor de parâmetros \mathbf{w} :

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0).$$

- Após a observação dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, como calcular a posteriori $p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$?

Regressão logística Bayesiana

- Considere um modelo de regressão logística binária:

$$\begin{aligned} p(\mathbf{y}|\mathbf{X}, \mathbf{w}) &= \prod_{i=1}^N \sigma(\mathbf{w}^\top \mathbf{x}_i)^{y_i} (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))^{1-y_i}, \quad y_i \in \{0, 1\}, \\ &= \prod_{i=1}^N \sigma_i^{y_i} (1 - \sigma_i^{1-y_i}), \end{aligned}$$

$$\text{em que } \sigma_i = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x}_i)}.$$

- Considere uma priori Gaussiana para o vetor de parâmetros \mathbf{w} :

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0).$$

- Após a observação dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, como calcular a posteriori $p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$? Sem solução analítica!

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a Hessiana do negativo da log-posteriori.

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a Hessiana do negativo da log-posteriori.
(calma, vamos justificar!)

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a Hessiana do negativo da log-posteriori.
(calma, vamos justificar!)
- Voltando à posteriori buscada:

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$$

$$\log p(\mathbf{w}|\mathcal{D}) = \log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w}) - \log p(\mathcal{D}),$$

$$\Psi(\mathbf{w}) = \log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w}).$$

- A média da aproximação será a solução MAP $\hat{\mathbf{w}}$ usual:

$$\hat{\mathbf{w}} = \arg \max \Psi(\mathbf{w})$$

Aproximação de Laplace

Teorema de Taylor para aproximação de funções

- Uma função real k vezes diferenciável em a pode ser aproximada por um polinômio de Taylor de ordem k :

$$f(x) \approx f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \dots + \frac{f^{(k)}(a)}{k!}(x-a)^k.$$

- Por conveniência, podemos truncar a série em uma ordem $< k$.

Aproximação de Laplace

Teorema de Taylor para aproximação de funções

- Uma função real k vezes diferenciável em a pode ser aproximada por um polinômio de Taylor de ordem k :

$$f(x) \approx f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \dots + \frac{f^{(k)}(a)}{k!}(x-a)^k.$$

- Por conveniência, podemos truncar a série em uma ordem $< k$.
- Escolhemos uma expansão de Taylor de segunda ordem (quadrática) para aproximar $\Psi(\mathbf{w})$ em torno de $\hat{\mathbf{w}}$:

$$\begin{aligned}\Psi(\mathbf{w}) &\approx \Psi(\hat{\mathbf{w}}) + (\mathbf{w} - \hat{\mathbf{w}})^\top \Psi'(\hat{\mathbf{w}}) + \frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \Psi''(\hat{\mathbf{w}})(\mathbf{w} - \hat{\mathbf{w}}) \\ &\approx \Psi(\hat{\mathbf{w}}) + \frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \Psi''(\hat{\mathbf{w}})(\mathbf{w} - \hat{\mathbf{w}}),\end{aligned}$$

em que $\Psi'(\hat{\mathbf{w}}) = 0$, pois $\hat{\mathbf{w}}$ é um máximo de $\Psi(\mathbf{w})$.

Aproximação de Laplace

- Podemos reescrever a aproximação:

$$\Psi(\mathbf{w}) \approx \Psi(\hat{\mathbf{w}}) - \frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}}),$$

em que $\mathbf{H} = -\Psi''(\hat{\mathbf{w}}) = -\nabla \nabla \Psi(\hat{\mathbf{w}})$

- Aplicamos uma exponencial em ambos os lados:

$$\begin{aligned} p(\mathbf{w}|\mathcal{D}) &\propto \exp(\Psi(\mathbf{w})) \\ &\propto \exp(\Psi(\hat{\mathbf{w}})) \exp\left(-\frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}})\right), \\ &\approx \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}). \end{aligned}$$

Aproximação de Laplace

- Podemos também aproximar a evidência:

$$\begin{aligned}\log p(\mathcal{D}) &= \log \int p(\mathcal{D}|\mathbf{w})p(\mathbf{w})d\mathbf{w} \\ &\approx \log \int \exp(\Psi(\mathbf{w}))d\mathbf{w} \\ &\approx \Psi(\hat{\mathbf{w}}) + \log \int \exp\left(-\frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}})\right) d\mathbf{w} \\ &\approx \log p(\mathcal{D}|\hat{\mathbf{w}}) + \log p(\hat{\mathbf{w}}) + \log \frac{(2\pi)^{M/2}}{|\mathbf{H}|^{1/2}} \\ &\approx \log p(\mathcal{D}|\hat{\mathbf{w}}) + \log p(\hat{\mathbf{w}}) + \frac{M}{2} \log 2\pi - \frac{1}{2} \log |\mathbf{H}|.\end{aligned}$$

Bayesian Information Criterion (BIC)

- Repetimos a evidência aproximada abaixo:

$$\log p(\mathcal{D}) \approx \log p(\mathcal{D}|\hat{\mathbf{w}}) + \log p(\hat{\mathbf{w}}) + \frac{M}{2} \log 2\pi - \frac{1}{2} \log |\mathbf{H}|.$$

- O índice BIC para comparação de modelos pode ser obtido após algumas considerações:

- Ignorar o termo constante;
- Uma priori uniforme para os parâmetros, o que torna $\hat{\mathbf{w}} = \mathbf{w}_{\text{ML}}$;
- Seja $\mathbf{H} = \sum_{i=1}^N \mathbf{H}_i$, em que $\mathbf{H}_i = \nabla \nabla \log p(\mathcal{D}_i|\mathbf{w})$.
Aproximando $\mathbf{H}_i = \hat{\mathbf{H}}$, podemos aproximar o termo $\log |\mathbf{H}|$:

$$\log |\mathbf{H}| \approx \log |N\hat{\mathbf{H}}| = \log(N^D |\hat{\mathbf{H}}|) = D \log N + \log |\hat{\mathbf{H}}|,$$

sendo D a dimensão de \mathbf{w} . O termo $\log |\hat{\mathbf{H}}|$ não depende de N e será dominado para N grande, podendo ser desprezado.

- A partir dos pontos acima o índice BIC é dado por:

$$\text{BIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \frac{D}{2} \log N.$$

Bayesian Information Criterion (BIC)

- Índice BIC para regressão linear/logística:

$$\text{BIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \frac{D}{2} \log N.$$

- De maneira mais geral, podemos considerar os graus de liberdade $\text{dof}(\mathbf{w})$ do modelo:

$$\text{BIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \frac{\text{dof}(\mathbf{w})}{2} \log N.$$

- Outro índice popular é o **Akaike Information Criterion (AIC)**:

$$\text{AIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \text{dof}(\mathbf{w}).$$

Regressão Logística Bayesiana

- Dada uma entrada \mathbf{x}_* , buscamos uma **distribuição preditiva**:

$$\begin{aligned}p(y_* = 1|\mathbf{x}_*, \mathcal{D}) &= \int p(y_*|\mathbf{x}_*, \mathbf{w})p(\mathbf{w}|\mathcal{D})d\mathbf{w} \\&\approx \int \sigma(\mathbf{w}^\top \mathbf{x}_*)\mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1})d\mathbf{w}, \\p(y_* = 0|\mathbf{x}_*, \mathcal{D}) &= 1 - p(y_* = 1|\mathbf{x}_*, \mathcal{D}).\end{aligned}$$

- A matriz $\mathbf{H} = -\nabla\nabla\Psi(\hat{\mathbf{w}})$ será dada por:

$$\begin{aligned}\mathbf{H} &= -\nabla\nabla[\log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w})]|_{\hat{\mathbf{w}}} = \mathbf{X}^\top \hat{\mathbf{R}}\mathbf{X} + \mathbf{S}_0^{-1}, \\ \hat{\mathbf{R}} &= \text{diag}(\hat{R}_{11}, \dots, \hat{R}_{NN}), \quad \hat{R}_{ii} = \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)(1 - \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)).\end{aligned}$$

- A distribuição preditiva não é analítica e precisa ser aproximada:
 - Aproximação de Monte Carlo;
 - Aproximação probit.

Regressão Logística Bayesiana - Monte Carlo

- Seguindo uma aproximação de **Monte Carlo**:

$$\begin{aligned} p(y_* = 1 | \mathbf{x}_*, \mathcal{D}) &\approx \int \sigma(\mathbf{w}^\top \mathbf{x}_*) \mathcal{N}(\mathbf{w} | \hat{\mathbf{w}}, \mathbf{H}^{-1}) d\mathbf{w}, \\ &= \frac{1}{S} \sum_{s=1}^S \sigma(\mathbf{w}_s^\top \mathbf{x}_*), \\ \mathbf{w}_s &\sim \mathcal{N}(\mathbf{w} | \hat{\mathbf{w}}, \mathbf{H}^{-1}). \end{aligned}$$


- Gerar amostras independentes de uma Gaussiana multivariada pode ser feito diretamente via pacotes estatísticos.
- Podemos reaproveitar as amostras $\mathbf{w}_s |_{s=1}^S$ para diferentes entradas.

Regressão Logística Bayesiana - aproximação probit

- A função logística $\sigma(z)$ pode ser aproximada pela função cumulativa (CDF) da distribuição Gaussiana normalizada:

$$\sigma(z) \approx \Phi(\lambda z), \quad \lambda = \sqrt{\pi/8},$$

$$\Phi(z) \triangleq \int_{-\infty}^z \mathcal{N}(z|0, 1) dz \quad (\text{função probit}).$$



Regressão Logística Bayesiana - aproximação probit

- Substituímos a função logística pela **função probit**:

$$p(y_* = 1 | \mathbf{x}_*, \mathcal{D}) \approx \int \Phi(\lambda \mathbf{w}^\top \mathbf{x}_*) \mathcal{N}(\mathbf{w} | \hat{\mathbf{w}}, \mathbf{H}^{-1}) d\mathbf{w}$$

- Note que o termo $\Phi(\lambda \mathbf{w}^\top \mathbf{x}_*)$ na verdade depende de um escalar $a = \mathbf{w}^\top \mathbf{x}_*$. Por isso, a integral se torna unidimensional:

$$p(y_* = 1 | \mathbf{x}_*, \mathcal{D}) \approx \int \Phi(\lambda a) \mathcal{N}(a | \mu_a, \sigma_a^2) da,$$

$$\mu_a = \hat{\mathbf{w}}^\top \mathbf{x}_*,$$

$$\sigma_a^2 = \mathbf{x}_*^\top \mathbf{H}^{-1} \mathbf{x}_*.$$

- Essa última integral possui a solução analítica abaixo:

$$p(y_* = 1 | \mathbf{x}_*, \mathcal{D}) \approx \Phi \left(\frac{\mu_a}{(\lambda^{-2} + \sigma_a^2)^{1/2}} \right) = \sigma((1 + \pi \sigma_a^2 / 8)^{1/2} \mu_a).$$

Regressão Logística Bayesiana

Resumo do algoritmo

- Passo de estimação

- 1 Defina a partir de conhecimentos/experimentos anteriores:
→ os momentos da priori $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0)$;
- 2 A partir dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, encontre a solução MAP para $\hat{\mathbf{w}}$ (e.g. via algoritmo IRLS).
- 3 Aproxime a posteriori de \mathbf{w} :

$$p(\mathbf{w}|\mathcal{D}) \approx \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}),$$

em que:

$$\mathbf{H} = \mathbf{X}^\top \hat{\mathbf{R}} \mathbf{X} + \mathbf{S}_0^{-1},$$

$$\hat{\mathbf{R}} = \text{diag}(\hat{R}_{11}, \dots, \hat{R}_{NN}),$$

$$\hat{R}_{ii} = \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)(1 - \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)).$$

- 4 Retorne a posteriori aproximada $p(\mathbf{w}|\mathcal{D})$ dos parâmetros.

Regressão Logística Bayesiana

Resumo do algoritmo

- Passo de predição
 - 1 Dado um padrão \mathbf{x}_* , retorne a distribuição preditiva:
 - Via aproximação de Monte Carlo:


$$p(y_* = 1|\mathbf{x}_*) \approx \frac{1}{S} \sum_{s=1}^S \sigma(\mathbf{w}_s^\top \mathbf{x}_*),$$
$$\mathbf{w}_s \sim \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}).$$

- Via aproximação probit:


$$p(y_* = 1|\mathbf{x}_*) \approx \sigma((1 + \pi\sigma_a^2/8)^{1/2}\mu_a),$$
$$\mu_a = \hat{\mathbf{w}}^\top \mathbf{x}_*,$$
$$\sigma_a^2 = \mathbf{x}_*^\top \mathbf{H}^{-1} \mathbf{x}_*.$$

Regressão Logística Bayesiana


Posterior decision boundary $N = 10$
Approximate evidence = $-1.769\text{e}+01$




Predictive distribution with Monte Carlo approximation
LPD = $-2.714\text{e}-02$




Predictive distribution with probit approximation
LPD = $-2.172\text{e}-02$




Posterior decision boundary $N = 50$
Approximate evidence = $-1.494\text{e}+01$




Predictive distribution with Monte Carlo approximation
LPD = $-6.512\text{e}-02$




Predictive distribution with probit approximation
LPD = $-6.258\text{e}-02$




Posterior decision boundary $N = 100$
Approximate evidence = $-1.367\text{e}+01$



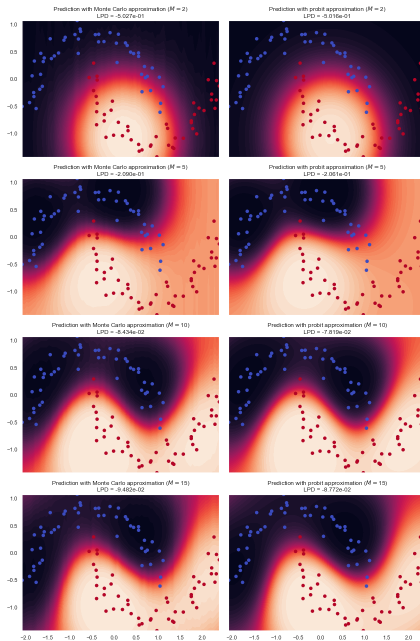
Predictive distribution with Monte Carlo approximation
LPD = $-5.192\text{e}-02$



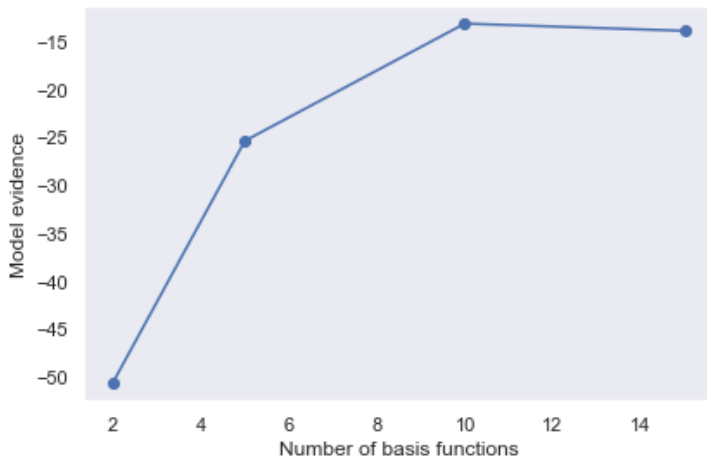
Predictive distribution with probit approximation
LPD = $-5.002\text{e}-02$



Regressão Logística RBF Bayesiana



Regressão Logística RBF Bayesiana



Agenda

- 1 Classificação binária
- 2 Regressão logística binária
- 3 Classificação logística multiclasse
- 4 Regressão logística via algoritmo IRLS
- 5 Regressão logística Bayesiana - Aproximação de Laplace
- 6 Tópicos adicionais
- 7 Referências

Tópicos adicionais

- Representação de atributos categóricos via one hot encoding.
 - **Exemplo:** Atributo “gênero de filme” (ação, drama ou comédia): $\mathbf{x}_i = [1 \ 0 \ 0]^\top$, ou $\mathbf{x}_i = [0 \ 1 \ 0]^\top$, ou $\mathbf{x}_i = [0 \ 0 \ 1]^\top$.
- Generalized linear models (GLMs).
- Regressão ordinal.

Agenda

- 1 Classificação binária
- 2 Regressão logística binária
- 3 Classificação logística multiclasse
- 4 Regressão logística via algoritmo IRLS
- 5 Regressão logística Bayesiana - Aproximação de Laplace
- 6 Tópicos adicionais
- 7 Referências

Referências bibliográficas

- **Cap. 8** - MURPHY, Kevin P. **Machine learning: a probabilistic perspective**, 2012.
- **Cap. 4** - BISHOP, Christopher M. **Pattern recognition and machine learning**, 2006.